

# Invocare API esterne in maniera efficiente con Amazon SQS e AWS Lambda

**Gabriele Postorino** 

Principal Technical Account Manager

**Amazon Web Services** 



#### **Gabriele Postorino**

Technical Account Manager AWS Enterprise Support

- Sicurezza
- Reliability
- Operations
- Performance
- Costi
- ..

- Migrazioni
- Go Live
- Eventi

#### **Focus**

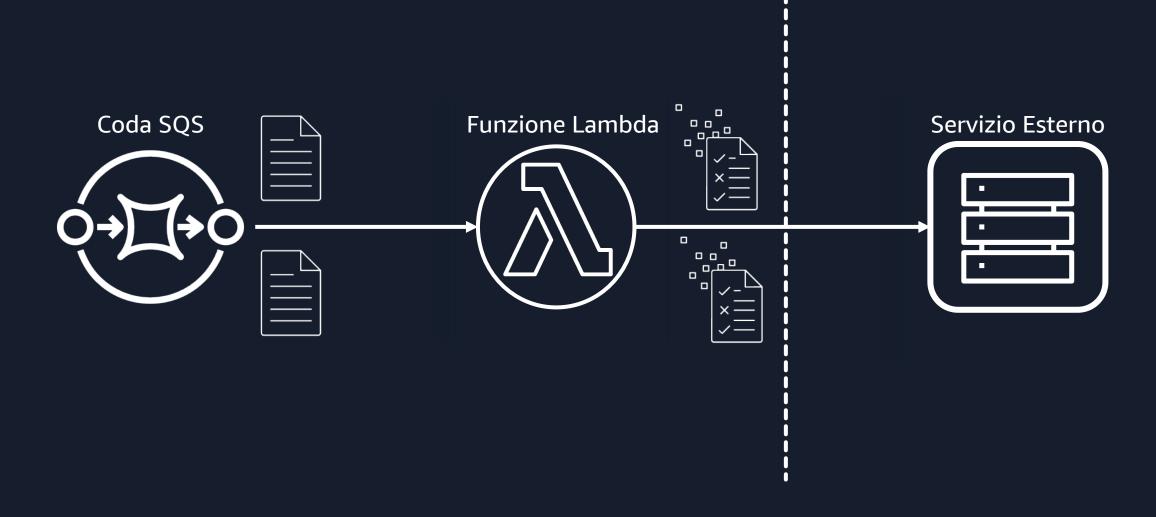
Scaling best practices Resilience





# Invocare API esterne in maniera efficiente con Amazon SQS e AWS Lambda

## Lo scenario





#### SQS event source mapping

POLLING AND BATCHING

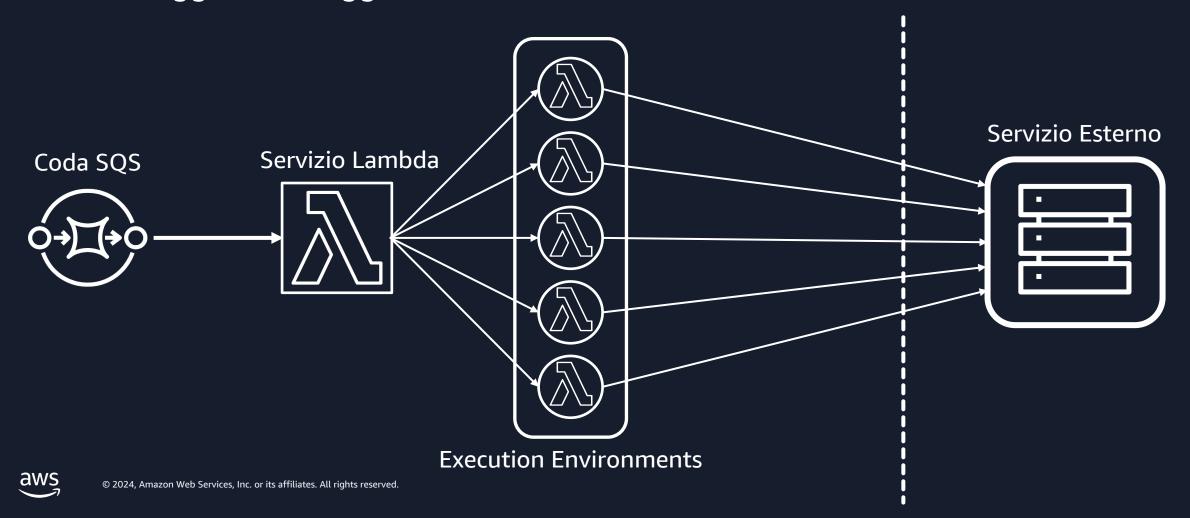
- Lambda legge i messaggi in coda e invoca la funzione attraverso un evento
- Ogni evento contiene un batch di messaggi di dimensione configurabile
- Quando l'esecuzione termina con successo i messaggi sono eliminati dalla coda



#### **SQS Event Source Mapping**

SCALING BEHAVIOUR

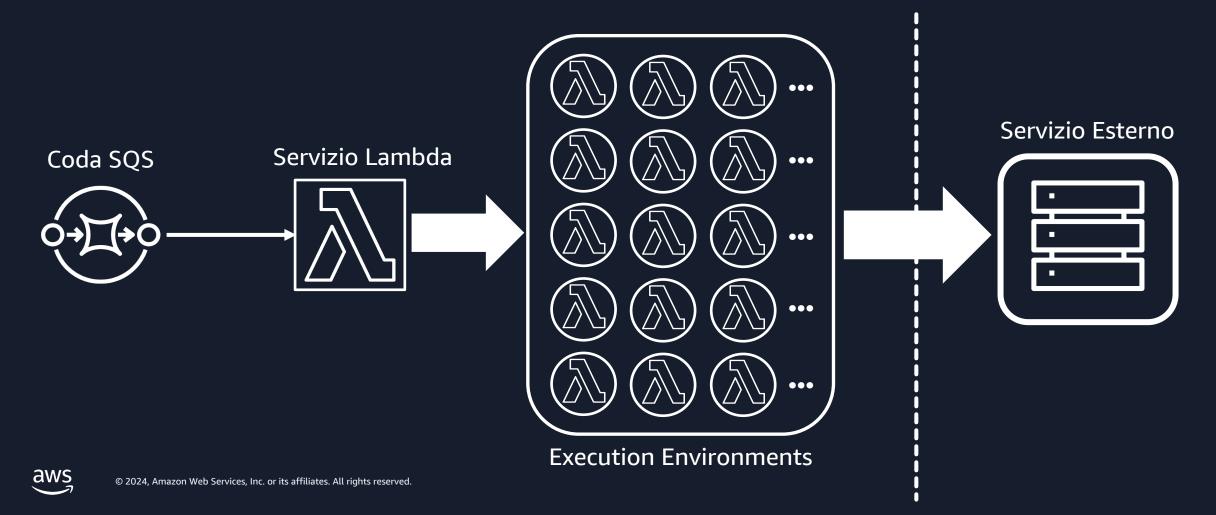
Lambda legge i messaggi in coda e invoca fino a 5 esecuzioni concorrenti



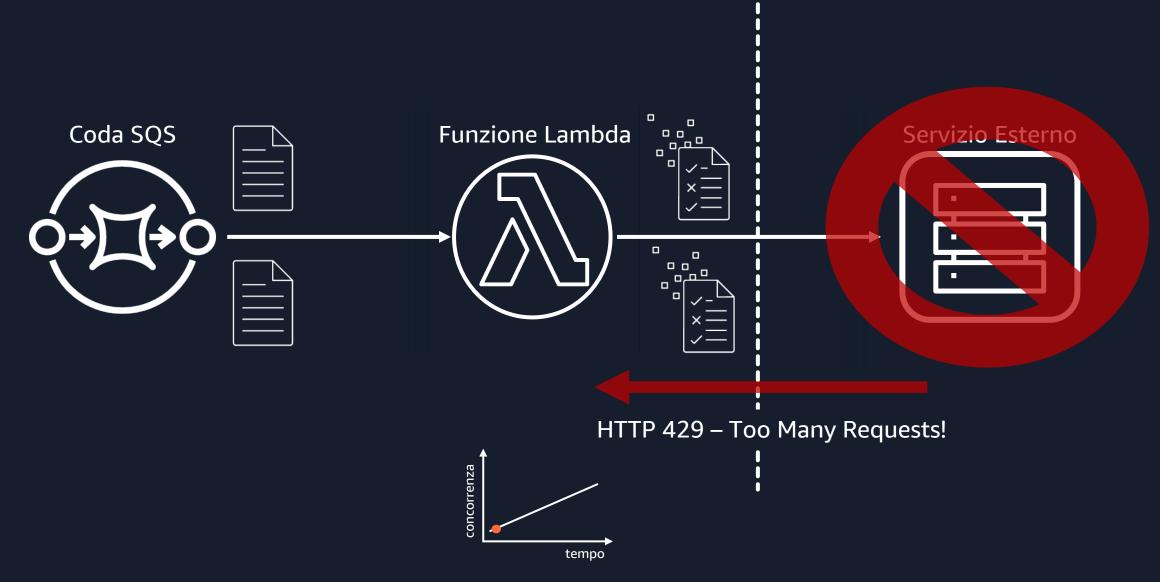
#### **SQS Event Source Mapping**

SCALING BEHAVIOUR

Può scalare fino a 1000 esecuzioni concorrenti gradualmente (+300/min)



## Lo scenario

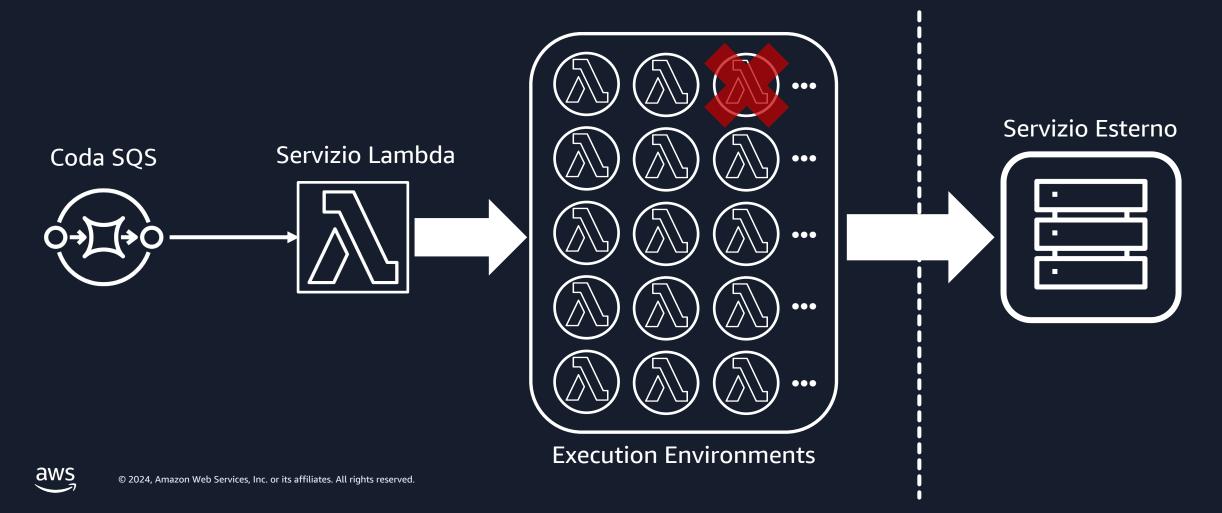




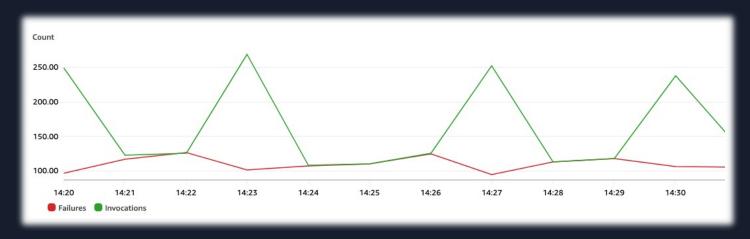
#### **SQS Event Source Mapping**

SCALING BEHAVIOUR

Quando una esecuzione fallisce, Lambda riduce la concorrenza in automatico



## Quindi, tutto ok?



Non proprio...

Se una esecuzione della funzione fallisce, tutti i messaggi del batch tornano in coda!



## Gestione degli errori

PARTIAL BATCH RESPONSES Coda SQS Funzione Lambda Servizio Esterno 10 messaggi/batch Failed Message Ids 7, 8, 9



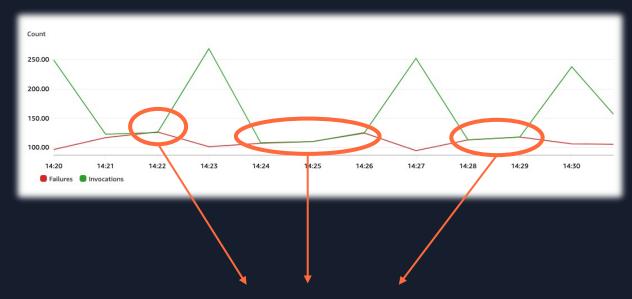
#### Gestione degli errori

RETRY

Riprovare automaticamente le operazioni che falliscono a causa di errori transitori migliora la resilienza dell'applicazione

Tentativi troppo frequenti possono però:

- 1. sovraccaricare i sistemi a valle
- 2. fallire nuovamente



Tutte le esecuzioni sono fallite



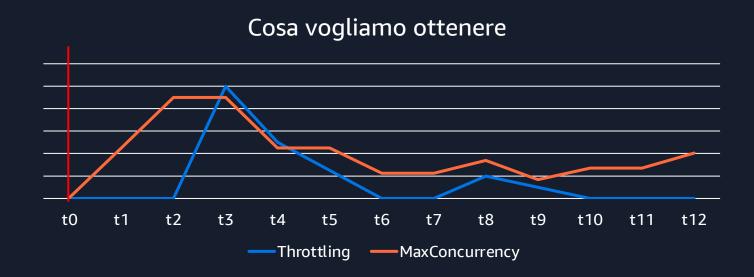
### Gestione degli errori

RETRY WITH BACKOFF



limita il numero di esecuzioni concorrenti di una funzione Lambda che una coda SQS può invocare

## Adaptive scaling



Vediamo come può essere implementato...



Metrica Cloudwatch per monitorare il livello di throttling

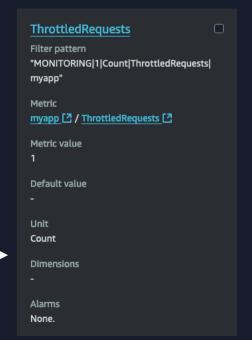
- 1. Richiede una chiamata verso CloudWatch
- 2. Aumenta il tempo di esecuzione della funzione
- 3. Genera costi aggiuntivi(API Call a CloudWatch + tempo di esecuzione lambda)



Metrica Cloudwatch per monitorare il livello di throttling

#### CW Logs metric filter

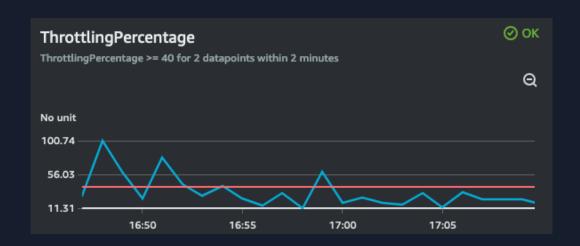
```
logger = logging.getLogger(__name__)
logger.setLevel("INF0")
namespace = 'myapp'
def send_metric(name, value, unit):
    logger.info(f"MONITORING|{value}|{unit}|{name}|{namespace}")
    return
 2024-11-06T17:19:19.224Z
                                  START RequestId: e361f182-13f6-50ae-87cc-ae27b4a1c0d0 Version: $LATEST
 START RequestId: e361f182-13f6-50ae-87cc-ae27b4a1c0d0 Version: $LATEST
 2024-11-06T17:19:19.505Z
                                  [WARNING] 2024-11-06T17:19:19.505Z e361f182-13f6-50ae-87cc-ae27b4a1c0d0 Messages failed to send to target Lambda function: Too Many Requests
                2024-11-06T17:19:19.505Z
                                             e361f182-13f6-50ae-87cc-ae27b4a1c0d0
                                                                                 Messages failed to send to target Lambda function: Too Many Requests
 2024-11-06T17:19:19.505Z
                                  [INFO] 2024-11-06T17:19:19.505Z e361f182-13f6-50ae-87cc-ae27b4a1c0d0 MONITORING|1|Count|ThrottledRequests|myapp
 [INFO] 2024-11-06T17:19:19.505Z
                                      e361f182-13f6-50ae-87cc-ae27b4a1c0d0 MONITORING|1|Count|ThrottledRequests|myapp
```

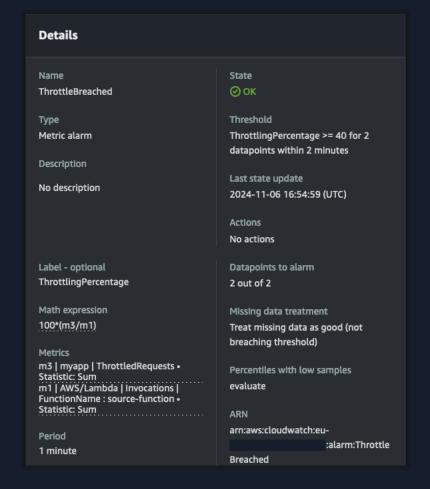




© 2024, Amazon Web Services, Inc. or its affiliates. All rights reserved.

Allarme su percentuale di throttling vs esecuzioni totali







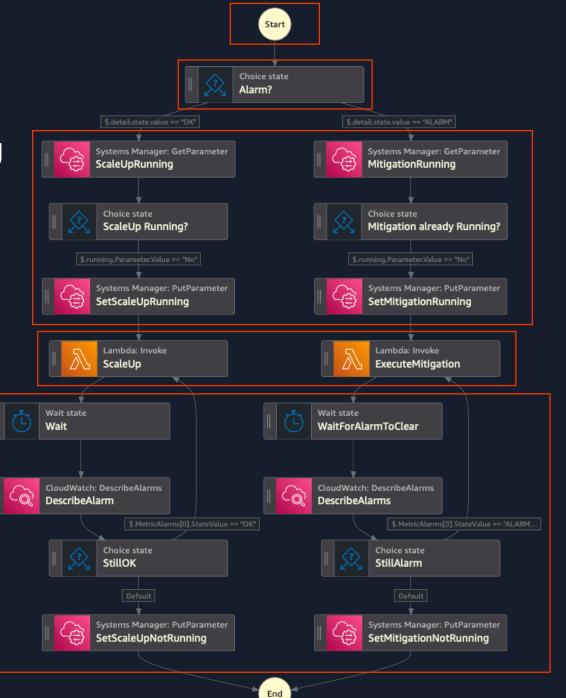
#### Step function per orchestrare lo scaling

Invocata da una regola di EventBridge sul cambiamento di stato del CloudWatch Alarm

Switch sullo stato dell'allarme:

- In allarme -> avvia scale down
- OK -> avvia scale up

Verifica se l'azione è già in corso, continua solo in caso negativo





#### Step function per orchestrare lo scaling

Esegue l'operazione di scale up o scale down

#### Scale down:

```
# Set new max concurrency to half

concurrency = int(max_concurrency/2) if int(max_concurrency/2) >=2 else 2

response = lambda_client.update_event_source_mapping(
    UUID=event_source_uuid,
    ScalingConfig={'MaximumConcurrency': concurrency })
```

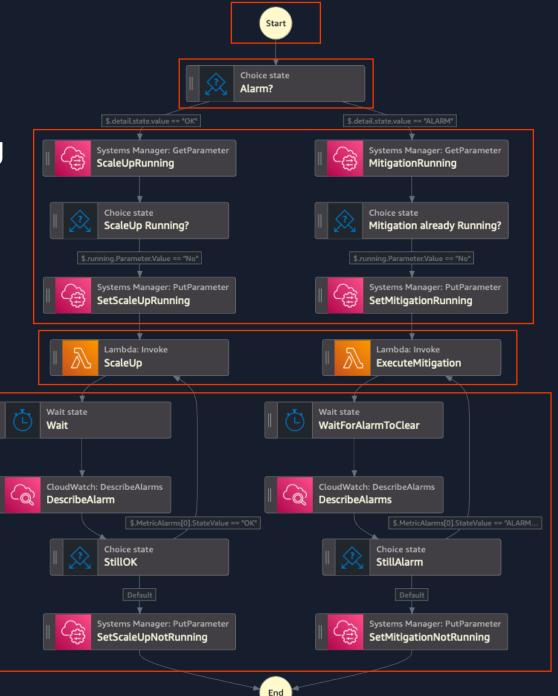
#### Scale up:

```
# Set new max concurrency to 50% more

concurrency = max(int(max_concurrency*1.5), 2)
concurrency = concurrency if concurrency < max_concurrency_limit else max_concurrency_limit

response = lambda_client.update_event_source_mapping(
    UUID=event_source_uuid,
    ScalingConfig={'MaximumConcurrency': concurrency }}</pre>
```

- aspetta per un determinato tempo
- verifica lo stato dell'allarme
- ripete l'azione se lo stato non è cambiato
- esce altrimenti



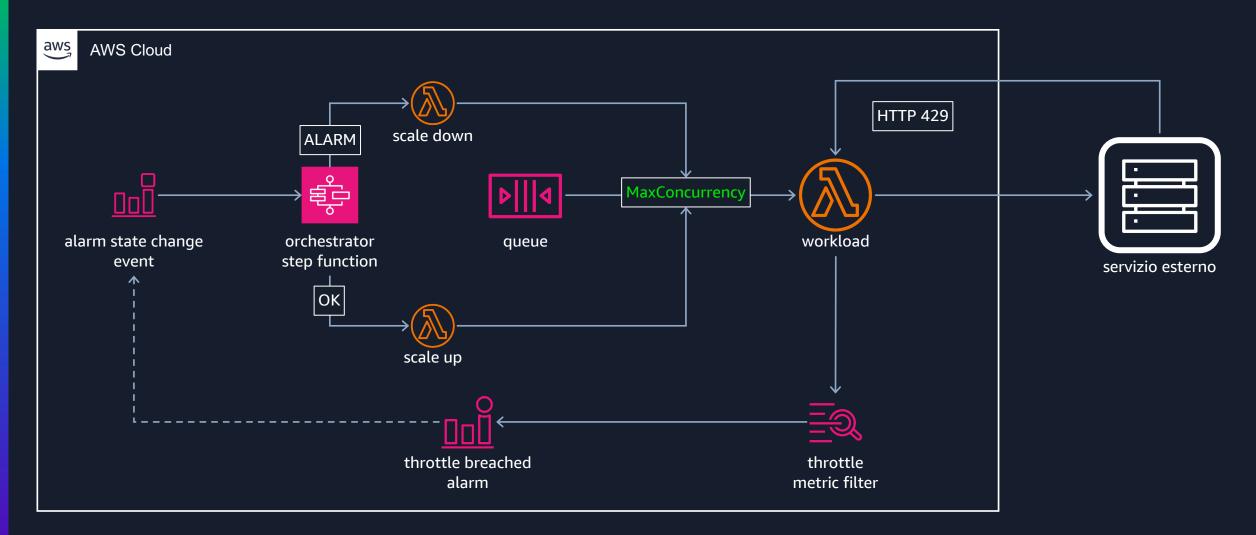


#### Risultato



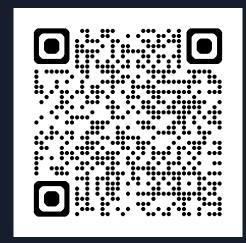


## Recap





#### Link utili



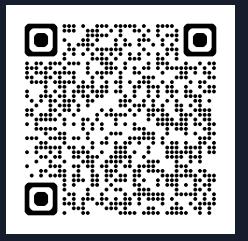
SQS Event Source Mapping Scaling behaviour



Partial batch responses best practices



Error Handling for SQS event source in Lambda



Retry with backoff pattern



## Thank you!

**Gabriele Postorino**Principal Technical Account Manager
Amazon Web Services





https://www.linkedin.com/in/gabrielepostorino/

